Universidade de Fortaleza

Inteligência Artificial Computacional: Construindo Modelos do Zero

Uma análise comparativa matemática e de performance entre classificadores e regressores programados exclusivamente em NumPy.

Project Dossier

Disciplina:	Inteligência Artificial Computacional
Instituição:	Centro de Ciências Tecnológicas - CCT / UNIFOR
Professora:	Dra. Cynthia Moreira Maia
Autores:	Matheus e Marcos
Data:	Maio 2026

NotebookLM

O Desafio Duplo sob Restrições Severas de Engenharia

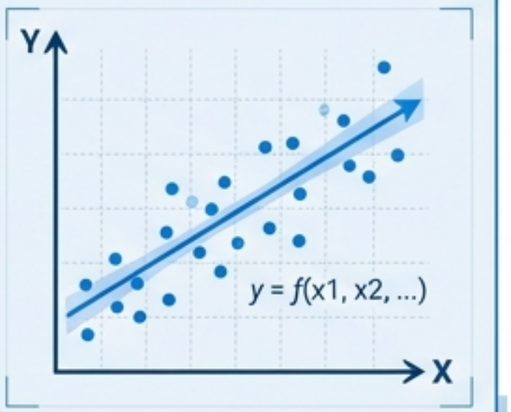
Objetivo 1: Classificação

Determinar a autenticidade de sites (Phishing vs. Legítimo) através de votação espacial e probabilidade matemática.



Objetivo 2: Regressão

Estimar um valor contínuo (preço de imóveis) através da análise de múltiplos atributos preditores.



Algorithmic Blueprint



A Regra de Ouro

Restrição Absoluta

Nenhuma biblioteca de Machine Learning de alto nível (scikit-learn) ou de manipulação de dados estruturados (pandas) permitida.

A Solução: Implementação 100% manual. Manipulação de arquivos .arff, matrizes de covariância e distâncias euclidianas calculadas na unha usando puramente álgebra linear e NumPy.

NotebookLM

Raio-X dos Conjuntos de Dados: As Arenas de Batalha

Card 1: Classificação (Phishing)

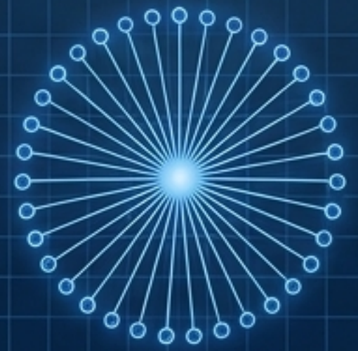
Fonte: phpV5QYya.arff (OpenML)

Volume: 11.055 instâncias

Dimensionalidade: 30 atributos preditores (descritores de URL)

Alvo (Target): Coluna Result

Classes: Vetor binário [-1, 1]



Algorithmic Blueprint

Card 2: Regressão (King County Houses)

Fonte: dataset.arff (OpenML)

Volume: 21.613 instâncias

Dimensionalidade: 21 atributos preditores

Alvo (Target): Coluna price (Valor contínuo)



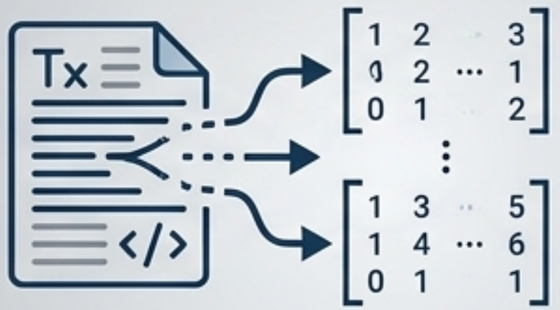
Nota Técnica: O alvo neste dataset não se encontra na última coluna, exigindo mapeamento específico da matriz de entrada (REGRESSION_TARGET = 'price'). A coluna 'id' foi isolada e removida das features de entrada X.

NotebookLM

Algorithmic Blueprint

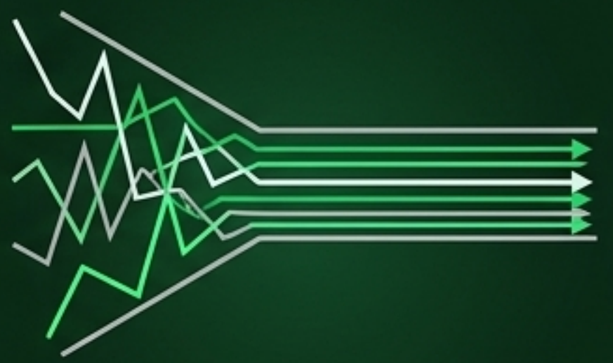
O Pipeline de Preparação: Arquitetura do Fluxo de Dados

1. Parse Manual de Dados



Leitura bruta ignorando cabeçalhos `@attribute` do `.arff`. Conversão de strings para floats e isolamento matricial de X (Features) e y (Target).

2. Normalização Min-Max



Prevenção de distorções em algoritmos de distância (ex: área da casa vs. número de banheiros).

Cálculo Crítico: Para evitar data leakage (vazamento de dados), o mínimo e máximo são calculados estritamente sobre os dados de Treino e posteriormente aplicados ao Teste.

3. Validação Cruzada (5-Fold)



Embaralhamento e divisão garante avaliação robusta contra sorte ou azar na seleção das amostras.

NotebookLM

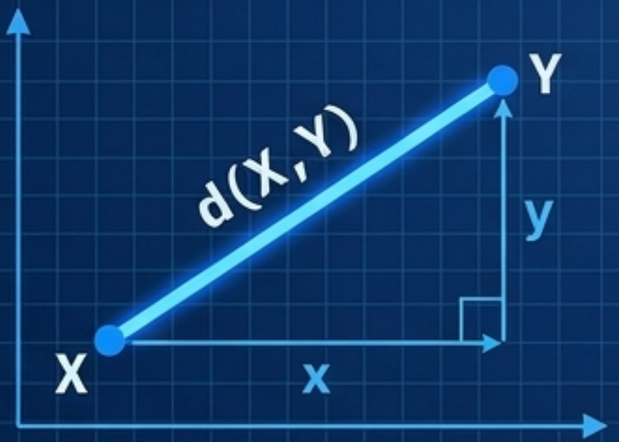
Algorithmic Blueprint

Dissecando o K-Nearest Neighbors: A Lógica Preguiçosa

O KNN não constrói um modelo matemático durante o treino. Ele decora o espaço de dados e atua apenas na inferência, avaliando os K=5 vizinhos **mais próximos** (votação na Classificação; média na Regressão).

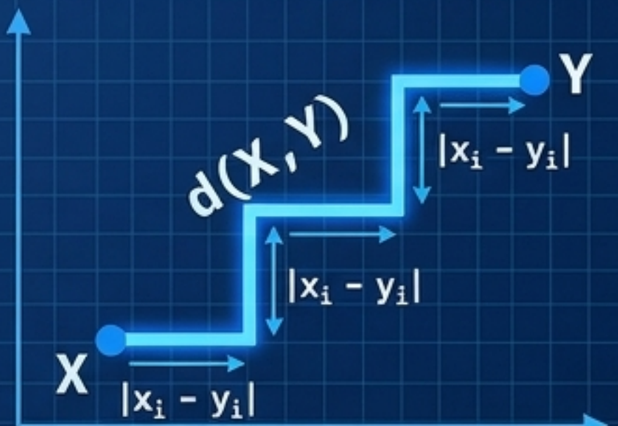
Distância Euclidiana

$$d(X,Y) = \sqrt{\sum(x_i - y_i)^2}$$



Distância Manhattan

$$d(X,Y) = \sum |x_i - y_i|$$

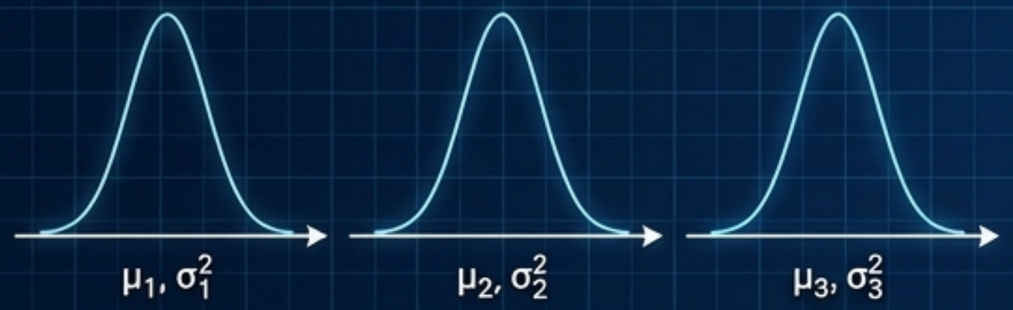


NotebookLM

Dissecando o Naive Bayes: A Perspectiva Probabilista

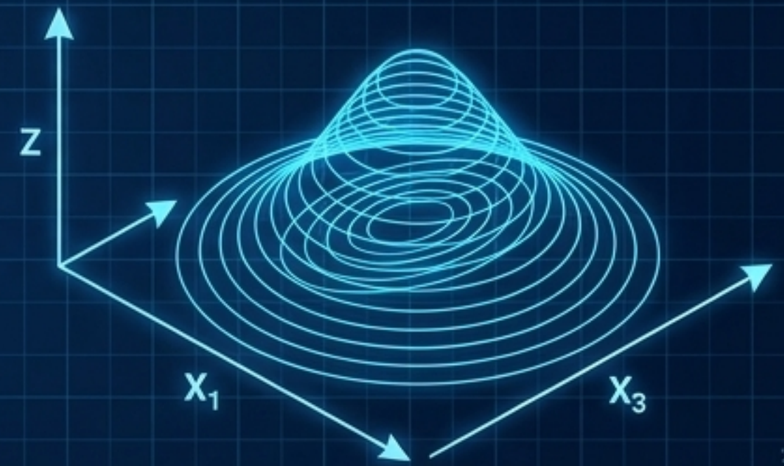
Baseado no **Teorema de Bayes**, avalia qual classe possui a maior probabilidade dadas as características da amostra.

Caso Univariado



Assume independência total. Avalia a média e variância de cada atributo de forma isolada em seu próprio silo matemático.

Caso Multivariado



Utiliza vetor de médias e a Matriz de Covariância (Σ) para compreender a correlação oculta entre os atributos.

⚠ **Intervenção no Código:** Injeção de uma constante minúscula (ruído) na diagonal principal de Σ para evitar o colapso de uma matriz singular durante a sua inversão.

NotebookLM

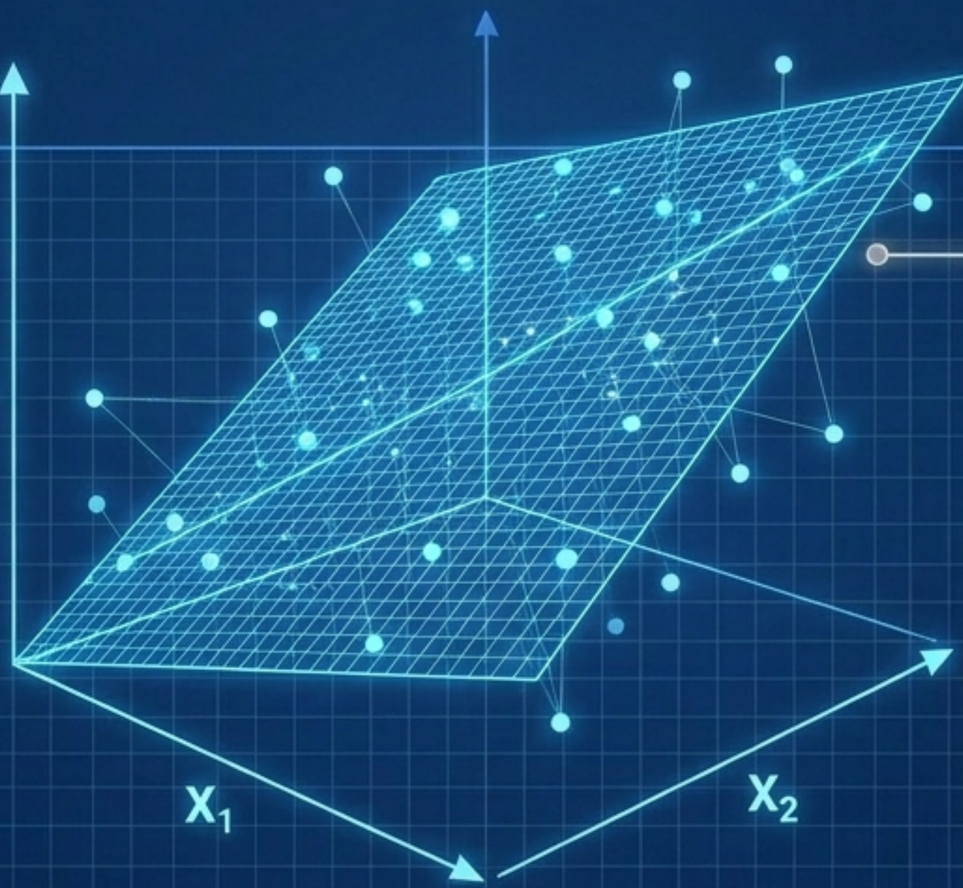
Algorithmic Blueprint

Dissecando a Regressão Linear: O Ajuste Perfeito em Múltiplas Dimensões

Tenta **prever o valor contínuo** traçando uma combinação linear que melhor se ajusta ao espaço tridimensional dos dados.

O **Equacionamento**:

$$y = b_0 + b_1x_1 + b_2x_2 + \ldots + b_nx_n$$



Solução Analítica Direta

$$\theta = (X^T X)^{-1} X^T y$$

Em vez de descida de gradiente pronta, o problema foi resolvido matricialmente de forma manual usando a Equação Normal. Utilizou-se a pseudo-inversa de Moore-Penrose para evitar instabilidade com matrizes de atributos altamente correlacionados.

NotebookLM

Algorithmic Blueprint

O Painel de Métricas: Estabelecendo o Sucesso

Desempenho de Classificação



- **Acurácia:** Taxa global de acertos sobre o total.
- **Precisão (Macro):** Confiabilidade da predição positiva.
- **Recall (Macro):** Capacidade de encontrar todos os positivos.
- **F1-Score:** A média harmônica entre Precisão e Recall.

Desempenho de Regressão



- **R^2 Score:** Proporção da variância do alvo (preço) explicada pelos atributos de entrada.
- **R^2 Ajustado:** Penaliza a inclusão de atributos irrelevantes no cálculo.

Eficiência Operacional



- **Tempo de Treino (s):** O custo para construir as premissas matemáticas e estruturar a matriz.
- **Tempo de Teste (s):** O custo computacional para realizar inferências cegas em tempo real no mundo real.

NotebookLM

Algorithmic Blueprint

Resultados: Detecção de Phishing (Classificação)

Modelo	Acurácia	Precisão	F1-Score	Treino (s)	Teste (s)
KNN Euclidiano	0.93 ± 0.01	0.93 ± 0.02	0.93 ± 0.02	0.01 ± 0.00	2.55 ± 0.10
KNN Manhattan	0.95 ± 0.01	0.95 ± 0.01	0.95 ± 0.01	0.01 ± 0.00	2.80 ± 0.12
Bayes Univariado	0.86 ± 0.02	0.86 ± 0.02	0.86 ± 0.02	0.04 ± 0.01	0.02 ± 0.00
Bayes Multivariado	0.89 ± 0.02	0.89 ± 0.02	0.89 ± 0.02	0.08 ± 0.01	0.02 ± 0.00

A Vitória: O KNN Manhattan prova superioridade absoluta no reconhecimento de padrões complexos.
O Prenúncio: Os tempos de teste do KNN mostram os primeiros sinais de um grave custo oculto.

NotebookLM

Algorithmic Blueprint

Resultados: Previsão de Preços de Imóveis (Regressão)

Modelo	R^2 Score	R^2 Ajustado	Treino (s)	Teste (s)
KNN Euclidiano	0.78 ± 0.02	0.78 ± 0.02	0.01 ± 0.00	3.90 ± 0.15
KNN Manhattan	0.82 ± 0.01	0.82 ± 0.01	0.01 ± 0.00	4.10 ± 0.18
Regressão Linear Múltipla	0.71 ± 0.03	0.70 ± 0.03	0.06 ± 0.01	0.01 ± 0.00

A Vitória Dupla: O KNN Manhattan repete o sucesso, superando a Regressão Linear na precisão contínua para estimar o valor financeiro das casas no dataset King County.

NotebookLM

Algorithmic Blueprint

A Pegadinha do Tempo: O Custo Oculto do Algoritmo Preguiçoso

Tornado Chart

O Milagre Paramétrico: Modelos Bayes e Lineares custam alguns segundos processando matrizes de covariância na largada, mas prevêem o futuro em milissegundos.



A Explosão Computacional: O KNN não treina. Mas na hora do teste, o código explode porque roda a equação de distância contra TODAS as amostras originais repetidas vezes.

NotebookLM

Algorithmic Blueprint

O Paradoxo da Escolha: Acurácia vs. Velocidade de Inferência

Y-Axis: Acurácia Preditiva
Preditiva (Baixa a Alta)

KNN
Manhattan

O Rei do Laboratório.
Decora perfeitamente, mas
pensa demais para responder.

O Ideal (Vazio)

Naive
Bayes

Regressão
Linear

Rápidos como um raio, com
perda matemática aceitável.

X-Axis: Velocidade de Inferência em Produção (Lento a Rápido)

Insight Crítico: O modelo de maior precisão matemática nem sempre se traduz no modelo viável para a engenharia de software em tempo real.

NotebookLM

Algorithmic Blueprint

Veredito Final: O Equilíbrio Ideal entre Rigor e Produção

Laboratório



Produção

Precisão Máxima

Se o poder de computação for infinito e o tempo for irrelevante (Pesquisa offline), o KNN Manhattan deve ser implementado. Ele é imbatível na taxa crua de acerto.

Eficiência Operacional

Se o sistema rodar na web para prever fraudes online em milissegundos, o tempo de latência do KNN colapsaria o servidor. Naive Bayes e Regressão Linear tornam-se os heróis da produção.

O Grande Aprendizado

Construir a estrutura na unha, sem scikit-learn ou pandas, comprovou na prática que o gargalo de complexidade não é apenas uma teoria de aula, mas um impacto direto na arquitetura.

NotebookLM

Algorithmic Blueprint

Algorithmic Blueprint

Fundações e Referências Bibliográficas

[ ] Cover, T. and Hart, P. "Nearest Neighbor Pattern Classification". (Fundação teórica das distâncias métricas).

[ ] Bishop, C. M. "Pattern Recognition and Machine Learning". (Base algorítmica paramétrica).

[ ] Murphy, K. P. "Machine Learning: A Probabilistic Perspective". (Matriz de covariância e Naive Bayes).

[ ] OpenML: www.openml.org (Origem controlada dos datasets phpV5QYya e dataset.arff).

NotebookLM